

МІНІСТЕРСТВО ОСВІТИ ТА НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ
«ХАРКІВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ»
КАФЕДРА КМАД

ЗВІТ З ЛАБОРАТОРНОЇ РОБОТИ №6

Виконав студент:

Омельніцький Андрій Миколайович
Група: КН-120А

Перевірила:

Ольга Василівна Костюк

Харків, 2023 г.

Зміст

1. Мета роботи	2
2. Основна частина	3
2.1. Пункт 1	3
2.2. Пункти 2-3	5
2.3. Пункт 4	6
2.4. Пункт 5	7
2.5. Пункт 6	8
2.6. Пункт 7	8
2.7. Пункти 8-9	10
3. Висновок	11
4. Код програми	12
4.1. main.py	12

Глава 1

Мета роботи

Вивчення математичної моделі на основі шаблонів, оптимізація моделі за різними критеріями.

Порядок виконання:

1. Використовуючи дані певного магазину, що надані викладачем за варіантом, навести повну характеристику даних, побудувати графіки.
2. Побудувати за даними (за виключенням останнього тижня) шаблони й модель на основі шаблонів.
3. Отримати прогнознi значення за моделлю на останній тиждень даних, порівняти з фактичними даними, зробити висновки.
4. Запропонувати критерій якості моделі. Вказати, яким чином цей критерій можна оптимізувати з метою підвищення якості прогнозування.
5. Виконати оптимізацію побудованої моделі, використовуючи в якості оптимізаційної змінної обмежену передісторію (змінну кількість тижнів) для побудови шаблонів моделі.
6. Виконати оптимізацію побудованої моделі, використовуючи в якості оптимізаційної змінної обмежену передісторію (змінну кількість тижнів) для адаптивного обчислення коефіцієнта.
7. Виконати оптимізацію побудованої моделі, використовуючи в якості шаблону найбільш схожий з попередніх днів.
8. Порівняти якість прогнозування отриманих моделей в пп. 5-7,
9. За результатами оптимізації надати рекомендації щодо побудови оптимальної прогнозної моделі.
10. Усі результати, отримані в ході виконання роботи, занести до звіту. Зробити висновки.

Глава 2

Основна частина

2.1. Пункт 1

Розглянемо данні магазину №530. За період від 2019-10-11 до 2020-01-28. Надалі й будемо розглядати данні цього магазину.

На рис. 2.4 представлений графік автокореляційної функції (АКФ) транзакцій магазину за період, що досліджується. З аналізу корелограми АКФ видно, що часовий ряд транзакцій містить явну циклічну компоненту з періодом $k = 24$. Зобразимо графіки що харектиризують данні.




Рис. 2.1. Погодинна динаміка транзакцій магазину




Рис. 2.2. Денний потік покупців за досліджуваний період




Рис. 2.3. Тижневий потік покупців за досліджуваний період.




Рис. 2.4. Графік АКФ транзакцій за досліджуваний період.

2.2. Пункти 2-3

Побудуємо шаблони та зобразимо їх графічно. Побудуємо два вида шаблонів за медіаною та за середнім. Але надалі будемо використовувати побудовані за медіаною.

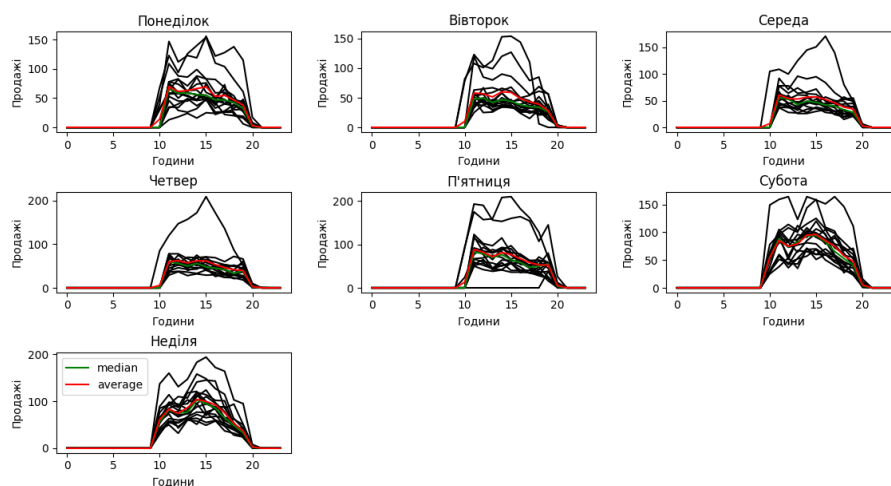


Рис. 2.5. Тижневий потік покупців за досліджуваний період та шабони побудовані за ними.

Отже для перевірки моделі побудуємо шаблон для нашого магазину на основі усіх даних окрім останнього тижня. А прогноз зробимо для вівторка останнього тижня.




Рис. 2.6. Прогноз

2.3. Пункт 4

Пропоную обрати в якості критерія якості моделі сумарну абсолютну різницю між прогнозом та реальними даними. Це допоможе аналізувати на скільки сумарно прогноз відхилився від реальних даних.

$$\sum_{i=0}^n (|\hat{x}_i - x_i|) \quad (1)$$

Де \hat{x}_i - значення прогнозу для години i . А x_i - значення реальних даних для години i .

2.4. Пункт 5

Подивимося як вплине на результативність моделі варіювання обсягу передісторії для обчислення шаблону. Для цього побудуємо графік де зобразимо залежність результатів функції (1) та обсягу передісторії. Та оримаємо, що краще буде обчислювати шаблон на всіх доступних даних.

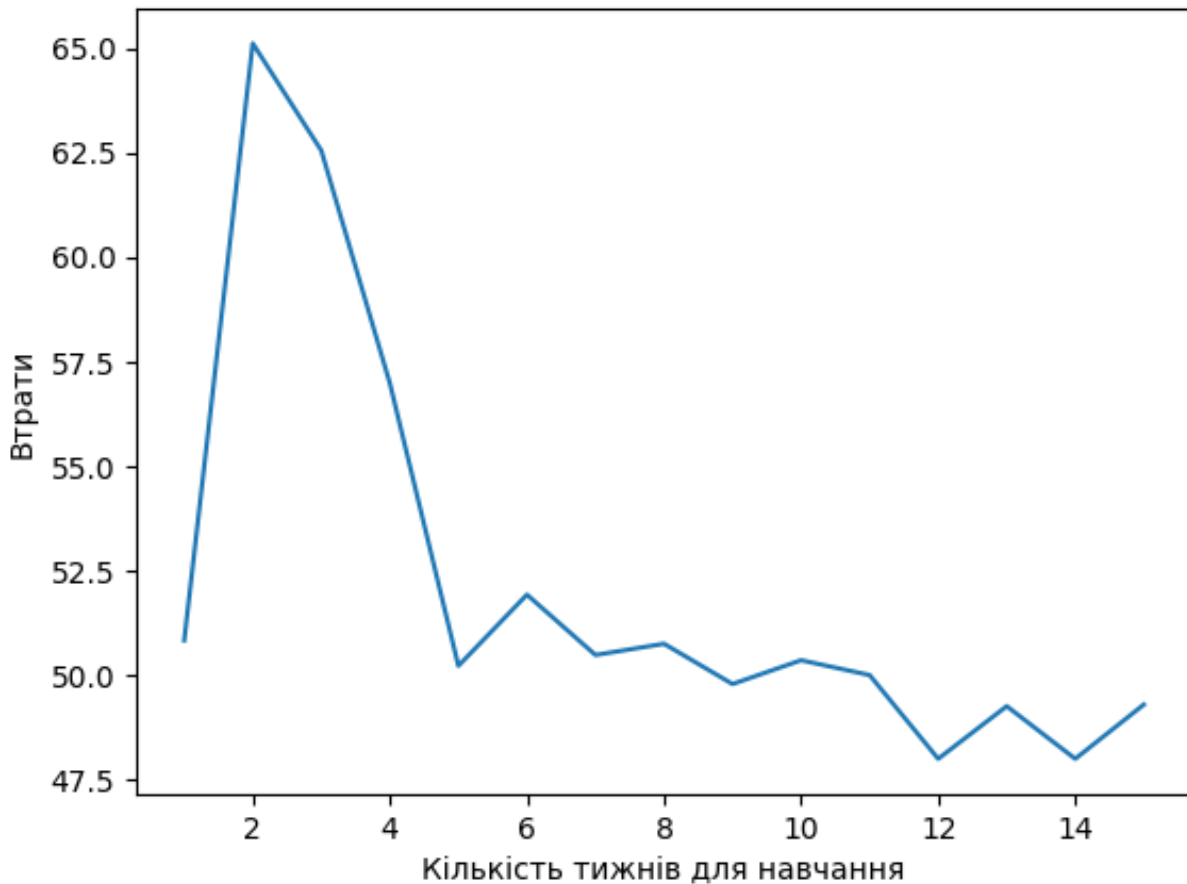


Рис. 2.7. Приклад

2.5. Пункт 6

Подивимося як вплине на результативність моделі варіювання обсягу передісторії для обчислення коефіцієнта. Для цього побудуємо графік де зобразимо залежність результатів функції (1) та обсягу передісторії. Та отримуємо, що краще буде обчислювати коефіцієнт тільки на даних поточного дня для якого й робиться прогноз.




Рис. 2.8. Приклад

2.6. Пункт 7

Подивимося як вплине на результативність моделі, якщо будемо обчислювати шаблон адаптивно. Тобто для поточної години для якої хочемо зробити прогноз будемо проводити аналіз усіх наявних шаблонів(Шаблонів по кожному дню). Для цього для поточної години та переісторії поточного дня будемо рахувати при якому шаблоні функція (1) буде давати мінімальне значення. Тоді за допомогою шаблону, який показав себе найкраще на передісторії і будемо рахувати наше пе-

редбачення. Якщо передісторія складається лише з нульових значень, то будемо обирати шаблон поточного дня тижня. Подивимося як ця оптимізація буде виглядати графічно.




Рис. 2.9. Приклад

Як можна помітити, що шаблон для поточного дня виявився оптимальним тому шаблони співпали. Тому розглянемо ще один приклад. Побудуємо шаблони на всіх даних окрім двох останніх тижнів. А прогноз будемо робити для п'ятниці передостаннього тижня.




Рис. 2.10. Приклад

У цьому випадку видно, що прогноз на адаптивному шаблоні кращий за звичайний. Але враховуючи випадкову природу значень прогноз за допомогою адаптивного шаблону може бути і гірший ніж за допомогою звичайного шаблону. Для кращого порівняння результатів цих шаблонів треба мати більшу передісторію для магазину, щоб сказати однозначно яких метод буде краще.

2.7. Пункти 8-9

При дослідженні моделі було отримано такі результати. Оптимальним буде використовувати всю наявну інформацію для побудови шаблонів. Для розрахунку коефіцієнта буде краще використовувати тільки передісторію поточного дня. А для обрання методу шаблону треба провести більш глибоке дослідження на більшій кількості даних. Тобто для оптимального розрахунку прогнозу треба максимально збільшити об'єм вхідних даних.

Глава 3

Висновок

У ході лабораторної роботи було побудована математична модель на основі шаблонів та оптимізовано модель за різними критеріями

Глава 4

Код програми

4.1. main.py

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 from statsmodels.graphics import tsaplots
5 from datetime import datetime, timedelta
6 import math
7
8
9 class PredictionModel:
10     def __init__(self):
11         self._template = np.zeros((7, 24))
12         self._shop_id = -1
13         self._data = None
14
15         self.week_day_by_int = {
16             0: " ",
17             1: " ",
18             2: " ",
19             3: " ",
20             4: " ",
21             5: " ",
22             6: " ",
23         }
24
25     def count_by_day_and_hour(self):
26         ...
27
28     def _count_average_template(self):
29         average = lambda sales: sales.mean()
30         self._count_template_by_sales(average)
31
32     def _count_median_template(self):
33         average = lambda sales: sales.median()
```

```

34         self._count_template_by_sales(average)
35
36     def _count_template_by_sales(self, func):
37         for i, day in enumerate(range(0, 7)):
38             all_week_day_data = self._data[self._data['
39                 week_day'] == day]
40             hours = all_week_day_data['time'].unique()
41
42             for j, hour in enumerate(hours):
43                 all_data_in_hour = all_week_day_data[self.
44                     _data['time'] == hour]
45                 sales = all_data_in_hour['All']
46
47                 self._template[i][j] = func(sales)
48
49     def _preparing_data_frame(self):
50         self._data["All"] = self._data["All"].replace(np.
51             nan, 0)
52         weeks_day = []
53         weeks_id = []
54         week_id = 0
55         last_week_day = 0
56         for date in self._data['date']:
57             date = datetime.strptime(date, "%Y-%m-%d").
58                 date()
59             weeks_day.append(date.weekday())
60             if date.weekday() == 0 and last_week_day == 6:
61                 week_id += 1
62             weeks_id.append(week_id)
63             last_week_day = date.weekday()
64
65         self._data['week_day'] = weeks_day
66         self._data['week_id'] = weeks_id
67
68     def _training_by_type(self, training_type):
69         if training_type == 'median':
70             self._count_median_template()
71         elif training_type == 'average':
72             self._count_average_template()

```

```

70 def training_model(self, data_frame, training_type='
    median'):
71     self._data = data_frame
72     self._preparing_data_frame()
73     self._training_by_type(training_type)
74
75 def _get_week_by_date(self, date):
76     week = [date]
77
78     date_now = date
79     while True:
80         # print(date_now, date_now.weekday())
81         date_now = date_now + timedelta(days=1)
82         if date_now.weekday() == 0:
83             break
84
85         week.append(date_now)
86
87     date_now = date
88     while True:
89         # print(date_now, date_now.weekday())
90         date_now = date_now - timedelta(days=1)
91         if date_now.weekday() == 6:
92             break
93
94         week.insert(0, date_now)
95
96     # print(date)
97     # print(week)
98     return week
99
100 def plot_statistic(self, plotted_days='__all__'):
101     if plotted_days == '__all__':
102         plotted_days = range(0, 7)
103
104     w = math.ceil(math.sqrt(len(plotted_days)))
105     h = math.ceil(len(plotted_days) / w)
106
107     plt.subplots_adjust(wspace=0.3, hspace=0.6)
108     axes = []
109

```

```

110     for i, day in enumerate(ploted_days):
111         ax = plt.subplot(h, w, i+1)
112         axes.append(ax)
113         ax.set_title(self.week_day_by_int[day])
114         ax.set_xlabel('')
115         ax.set_ylabel('')
116
117     for i, day in enumerate(ploted_days):
118         all_week_day_data = self._data[self._data['
119             week_day'] == day]
120         weeks_dates = all_week_day_data['date'].unique
121             ()
122         for week_date in weeks_dates:
123             week_data = all_week_day_data[self._data['
124                 date'] == week_date]
125
126             sales = week_data['All']
127             hours = week_data['time']
128             axes[i].plot(hours, sales, color='black')
129
130     reserve_template = self._template.copy()
131
132     self._training_by_type('median')
133     for i, day in enumerate(ploted_days):
134         sales = self._template[day]
135         hours = range(0, 24)
136
137         axes[i].plot(hours, sales, color='g', label='
138             median')
139
140     self._training_by_type('average')
141     for i, day in enumerate(ploted_days):
142         sales = self._template[day]
143         hours = range(0, 24)
144
145         axes[i].plot(hours, sales, color='r', label='
146             average')
147
148     self._template = reserve_template
149
150     plt.legend()

```



```

146     plt.show()
147
148     def _count_k(self, week_day, data):
149         if len(data) == 0:
150             return 1
151         if data.iloc[-1]['All'] == 0:
152             return 1
153
154         n = 0
155         result = 0
156         for hour_data_id in range(len(data)):
157             hour_data = data.iloc[hour_data_id]
158             if self._template[week_day][hour_data['time']]
159                 == 0:
160                 continue
161
162             n += 1
163             result += hour_data['All'] / self._template[
164                 week_day][hour_data['time']]
165
166         if n == 0:
167             return 1
168         return result / n
169
170     def predict(self, week_day, hour, history, sub_history
171 =None, is_adapt_template=False, template_id=None):
172         if hour == 0:
173             if template_id is not None:
174                 template_id.append(week_day)
175             return 0
176         if sub_history is None:
177             k = self._count_k(week_day, history)
178         else:
179             k = self._count_k(week_day, pd.concat([
180                 sub_history, history]))
181
182         if is_adapt_template:
183
184             sales = []
185             for j in range(len(history)):
186                 t_h = history.iloc[:j]

```

```

183         sales.append(self.predict(week_day, j, t_h
184                                 , sub_history))
185
186     min_val = self.count_lost(list(history['All'])
187                               , sales)
188     t_id = week_day
189     for i in range(self._template.shape[0]):
190         sales = []
191         for j in range(len(history)):
192             t_h = history.iloc[:,j]
193             sales.append(self.predict(i, j, t_h,
194                                     sub_history))
195
196     res = self.count_lost(list(history['All'])
197                           , sales)
198     # if hour < 12:
199     #     print(f'{history["All"]=}')
200     #     print(f'{sales=}')
201     #     print(f'{res=}')
202     #     print(f'{min_val=}')
203     #     print(f'{t_id=}')
204
205     # print('='*20)
206     # print(f'{i=}')
207     # print(f'{res=}')
208     # print(f'{min_val=}')
209     # print(f'{t_id=}')
210     # print('='*20)
211     if min_val > res:
212         min_val = res
213         t_id = i
214
215     return self.predict(t_id, hour, history,
216                        sub_history, template_id=template_id)
217 else:
218     if template_id is not None:
219         template_id.append(week_day)
220         template = self._template[week_day][hour]
221         return k * template
222
223 def count_lost(self, real, predicted):

```

```
219     assert len(real) == len(predicted)
220
221     lost = 0
222     for i in range(len(real)):
223         lost += abs(real[i] - predicted[i])
224
225     return lost
```

```
228 def set_title(title: str):
229     plt.get_current_fig_manager().set_window_title(title)
```

```
232 def plot_traj_dynamic(df):
233     sales = []
234     dates = df['date'].unique()
235     dates_p = []
236     for date in dates:
237         data_date = df[df['date'] == date]
238         sales.append(sum(data_date['All']))
239         dates_p.append(datetime.strptime(date, "%Y-%m-%d")
240                        .date())
```

```
241     plt.xlabel('')
242     plt.ylabel('')
243     plt.bar(dates_p, sales, color='black')
244     plt.show()
```

```
247 def plot_flow_of_customers(df):
248     sales = df['All']
249     hours = df['time']
250     plt.xlabel('')
251     plt.ylabel('')
252     plt.scatter(hours, sales)
253     plt.show()
```

```
256 def plot_weekly_flow_of_customers(df):
257     weeks = df['week_id'].unique()
258     for week in weeks:
```

```
259     week_data = df[df['week_id'] == week]
260     hours = week_data['time'] + 24 * week_data['
        week_day']
261     sales = week_data['All']
262     plt.plot(hours, sales, color='black', linewidth
        =0.7)
263
264     plt.show()
265
266
267 def plot_autocorrelation(df):
268     x = df['All']
269     fig = tsaplots.plot_acf(x, lags=35)
270     plt.show()
271
272
273 def test_predict(df):
274     df = df.copy()
275     model = PredictionModel()
276     model.training_model(df)
277
278
279     last_week_id = (df['week_id'].unique()[-1])
280     t_data = df[df['week_id'] != last_week_id]
281     r_data = df[df['week_id'] == last_week_id]
282     # print(t_data)
283     # print(r_data)
284
285
286     model.training_model(t_data)
287     # model.training_model(t_data, 'average')
288     # model.plot_statistic('__all__')
289
290
291     day = 1
292     # print(r_data)
293     target_date = r_data[r_data['week_day'] == day].iloc
        [-1]['date']
294     target_data = r_data[r_data['date'] == target_date]
295
296     # print(f'{target_date=}')
```

```

297     # print(target_data)
298
299     y = []
300     k = []
301     sales = target_data
302     hours = target_data['time']
303     for t in range(len(sales)):
304         y.append(model.predict(day, t, sales.iloc[:t]))
305         k.append(model._count_k(day, sales.iloc[:t]))
306
307     ax = plt.subplot(1, 1, 1)
308     ax_sub = ax.twinx()
309     ax_sub.set_ylim(-1.5, 1.5)
310     mark = '.'
311     ax.plot(hours, sales['All'], marker=mark, label='
312         ', color='r')
313     ax.plot(hours, y, marker=mark, label='
314         ', color='black')
315     ax.plot(hours, model._template[day], marker=mark,
316             label='
317             ', color='b')
318     ax_sub.plot(hours, k, marker=mark, label='
319         _k', color='g')
320
321     # print(sales, y)
322     lost = model.count_lost(list(sales['All']), list(y))
323     print(f'lost={lost}')
324     set_title(f'date:{target_date} week_id:{model.
325         week_day_by_int[day]}')
326
327     ax.legend()
328     ax_sub.legend()
329     plt.show()
330
331
332 def test_predict_for_template(df):
333     df = df.copy()
334     model = PredictionModel()
335     # model.training_model(df, 'average')
336     model.training_model(df)
337
338     last_week_id = (df['week_id'].unique()[-1])

```

```

333     losts = []
334     for id_temp in range(last_week_id):
335         t_data = df[df['week_id'] <= id_temp]
336         r_data = df[df['week_id'] == last_week_id]
337         # print(t_data)
338         # print(r_data)
339
340
341         model.training_model(t_data)
342
343
344         day = 1
345         # print(r_data)
346         target_date = r_data[r_data['week_day'] == day].
347             iloc[-1]['date']
348         target_data = r_data[r_data['date'] == target_date
349             ]
350
351         # print(f'{target_date=}')
352         # print(target_data)
353
354         y = []
355         k = []
356         sales = target_data
357         hours = target_data['time']
358         for t in range(len(sales)):
359             y.append(model.predict(day, t, sales.iloc[:t])
360             )
361             k.append(model._count_k(day, sales.iloc[:t]))
362
363         lost = model.count_lost(list(sales['All']), list(y
364             ))
365         losts.append(lost)
366
367     plt.plot(range(last_week_id), losts)
368     plt.show()
369
370 def test_predict_for_k(df):
371     df = df.copy()
372     model = PredictionModel()

```

```

370 # model.training_model(df, 'average')
371 model.training_model(df)
372
373
374 last_week_id = (df['week_id'].unique()[-1])
375 t_data = df[df['week_id'] != last_week_id]
376 r_data = df[df['week_id'] == last_week_id]
377 # print(t_data)
378 # print(r_data)
379
380
381 model.training_model(t_data)
382
383
384 day = 1
385 # print(r_data)
386 target_date = r_data[r_data['week_day'] == day].iloc
    [-1]['date']
387 target_data = r_data[r_data['date'] == target_date]
388
389
390 losts = []
391 for id_temp in range(last_week_id):
392     y = []
393     k = []
394     # history_added = df[(df['week_id'] <= id_temp) &
    (df['week_day'] == day)]
395     history_added = df[(df['week_id'] <= id_temp)]
396     sales_traget = target_data['All']
397     hours = target_data['time']
398     for t, value in enumerate(sales_traget):
399         sales = target_data.iloc[:t]
400         # print(f'{history_added=}')
401         # print(f'{sales=}')
402         # print(f'{target_data.iloc[:t+1]=}')
403         y.append(model.predict(day, t, sales,
            history_added))
404         k.append(model._count_k(day, sales))
405
406     lost = model.count_lost(list(sales_traget), list(y
    ))

```

```
407         losts.append(lost)
```

```
408
409 plt.plot(range(last_week_id), losts)
410 plt.show()
411
```

```
412
413 def test_predict_adapt(df):
```

```
414     df = df.copy()
415     model = PredictionModel()
416     model.training_model(df)
417
```

```
418
419     last_week_id = (df['week_id'].unique()[-1])
420     t_data = df[df['week_id'] != last_week_id]
421     r_data = df[df['week_id'] == last_week_id]
422
```

```
423     # last_week_id = (df['week_id'].unique()[-2])
424     # t_data = df[df['week_id'] < last_week_id]
425     # r_data = df[df['week_id'] == last_week_id]
426     # print(t_data)
427     # print(r_data)
428
```

```
429
430     model.training_model(t_data)
431     # model.training_model(t_data, 'average')
432     # model.plot_statistic('__all__')
433
```

```
434
435     day = 1
436     # day = 4
437     # print(r_data)
438     target_date = r_data[r_data['week_day'] == day].iloc
439         [-1]['date']
440     target_data = r_data[r_data['date'] == target_date]
441
442     # print(f'{target_date=}')
443     # print(target_data)
444
```

```
445     y = []
446     y1 = []
447     k = []
```



```

447 sales = target_data
448 hours = target_data['time']
449 template = []
450 for t in range(len(sales)):
451     t_id = []
452     y.append(model.predict(day, t, sales.iloc[:t],
453                             is_adapt_template=True, template_id=t_id))
454     y1.append(model.predict(day, t, sales.iloc[:t]))
455     template.append(t_id[0])
456     k.append(model._count_k(t_id[0], sales.iloc[:t]))
457
458 print(f'templates_ids: {template}')
459 template_prep = [model._template[ti][i] for i, ti in
460                  enumerate(template)]
461
462 ax = plt.subplot(1, 1, 1)
463 ax_sub = ax.twinx()
464 ax_sub.set_ylim(-1.5, 1.5)
465 mark = '.'
466 ax.plot(hours, sales['All'], marker=mark, label='
467         ', color='r')
468 ax.plot(hours, y, marker=mark, label='
469         ',
470         color='black')
471 ax.plot(hours, y1, marker=mark, label='
472         ',
473         color='#FF8833')
474 ax.plot(hours, template_prep, marker=mark, label='
475         ', color='b')
476 ax.plot(hours, model._template[day], marker=mark,
477         label='
478         ',
479         color='y')
480 ax_sub.plot(hours, k, marker=mark, label='
481         k', color='g')
482
483 # print(sales, y)
484 lost = model.count_lost(list(sales['All']), list(y))
485 lost1 = model.count_lost(list(sales['All']), list(y1))
486 print(f'lost_adapt={lost}')
487 print(f'lost={lost1}')
488 set_title(f'date:{target_date}; \tweek_day:{model.
489         week_day_by_int[day]}')

```

```
476
477     ax.legend()
478     ax_sub.legend()
479     plt.show()
480
481
482 def main():
483     df = pd.read_csv('/home/blackgolyb/Documents/labs_opt
484                       /6/data.csv', sep=';')
485     df = pd.read_csv('data.csv', sep=';')
486     df = df.set_index('index')
487     df_res = df.copy()
488
489     model = PredictionModel()
490     # model.training_model(df, 'average')
491     model.training_model(df)
492
493     plot_traj_dynamic(df)
494     plot_flow_of_customers(df)
495     plot_weekly_flow_of_customers(df)
496     plot_autocorrelation(df)
497     model.plot_statistic('__all__')
498
499     test_predict(df_res)
500     test_predict_for_template(df_res)
501     test_predict_for_k(df_res)
502     test_predict_adapt(df_res)
503
504
505 if __name__ == '__main__':
506     main()
```